Голдаев Сергей

Data Scientist

Томск Возраст: 22 года

О себе

Data Sceintist. Специализация: классический ML ,end-to-end внедрение моделей в прод. Опыт работы с feature engineering, несбалансированными данными, интерпретацией моделей.

Образование

- **НИТПУ, Бакалавр** 2026
  Инженерная школа информационных технологий и робототехники, Программная инженерия

Задачи

- *Кредитный скоринг:*

  Задача: Разработал производственный ETL-конвейер для автоматизации подготовки данных кредитного риска. Обучил модель для выбора выдачи кредита.

  Решение:
  • Разработал автоматизированный ETL-конвейер для обработки данных кредитныхрисков с оркестрацией через Apache Airflow и ежедневным запуском по расписанию
  • Реализовал модуль предобработки данных с интеллектуальным определением типов признаков и автоматическим заполнением пропусков
  • Построил feature engineering-модуль с расчётом ключевых финансовых метрик: DTI, агрегация задолженностей из кредитного бюро,классификация заёмщиков по семейному профилю
  • Спроектировал многослойную архитектуру хранения данных: загрузка из PostgreSQL → трансформация → сохранение в схему DWH, готовую для ML-моделирования
  • Разработал модуль EDA для визуального анализа факторов дефолта: распределение возраста, зависимость платёжеспособности от дохода и количества детей
  • Построил модель Gradient Boosting (CatBoost, ROC-AUC 0.83)

- *Прогноз стоимости дома:*

  Цель: Построить регрессионную модель для предсказания стоимости жилья на основе 80+ признаков с применением автоматического подбора гиперпараметров.

  Решение:

Контакты

+7 923 612-54-42
sergej.goldaev@mail.ru

Гражданство:
Россия

Занятость:
Полная занятость, полный день

- Провёл анализ мультиколлинеарности признаков и удалил высококоррелированные
переменные (порог > 0.7), снизив размерность данных
- Разработал два раздельных preprocessing-пайплайна (sklearn Pipeline + ColumnTransformer): с OneHotEncoding для линейных моделей и OrdinalEncoding для деревьев
- Обучил и сравнил 5 моделей: Linear Regression, Ridge, Lasso, Random Forest, CatBoost — с оценкой по MAE, MSE, R^2
Автоматизировал
подбор гиперпараметров с помощью Optuna (100 триалов) для Random Forest и CatBoostRegressor, оптимизируя по MAE

■

Отток клиентов:

Цель: Построить бинарный классификатор для предсказания оттока клиентов телеком-компании с оптимизацией по метрике AUC.

Решение:
- Провёл очистку данных: удаление дубликатов, обработка скрытых пропусков (пробелы как NaN), заполнение пропусков
средним значением
- Спроектировал новые признаки: ARPU (среднемесячная выручка на клиента = TotalSpent / ClientPeriod) и FamilyStatus (4 категории семейного положения) для обогащения профиля клиента
- Реализовал ручное кодирование категориальных переменных с учётом
смысловой упорядоченности (тип контракта, способ оплаты, тип интернета)
- Обучил CatBoostClassifier с GridSearchCV (5-fold CV) по4 значениям n_estimators, с early stopping и loss_function CrossEntropy; метрика оценки ROC-AUC (0.91)

■

LLM в веб-приложение для личных финансов:

Цель: Интегрировать LLM в веб-приложение для личных финансов (FinTracker) для автоматизации ввода расходов и предоставления персонализированных финансовых советов.

Решение:
- Подключил Google Gemini 2.5 Flash через google-generativeai SDK; вынес вызовы в asyncio.to_thread , чтобы не блокировать асинхронный FastAPI-сервер
- Реализовал **ИИ-ассистента** с персональным контекстом: каждый запрос к модели включает финансовый профиль пользователя (доход, лимит расходов, финансовая цель) и последние 30 транзакций — модель отвечает конкретными советами на основе реальных данных
- Реализовал **систему чат-сессий**: история диалога хранится в PostgreSQL и передаётся в Gemini через start_chat(history=...) , что обеспечивает связный многоходовой разговор
- Реализовал **Quick Import** — парсинг трат из свободного текста и фото чеков: изображение передаётся как multipart-контент в Gemini (vision), ответ модели — JSON-массив транзакций с автоматической категоризацией (food, transport, health и т.д.); реализована защитная валидация и восстановление на случай нестрогого JSON в ответе модели
- Спроектировал REST API: 6 эндпоинтов (/sessions , /chat , /parse) с JWT-авторизацией и проверкой владельца ресурса

Information Extraction из неструктурированного текста с LLM:

Цель: Автоматизировать извлечение числовых данных из неструктурированных текстовых объявлений с помощью LLM — определить количество человек, которым нужно жильё, по тексту объявления.

Решение:

- Подключил LLM (Qwen 3.5 Flash) через langchain-openai + ChatOpenAI с кастомным base_url , используя совместимый с OpenAI API эндпоинт
- Написал PromptTemplate с переменной {query} для батч-обработки: модель получает текст объявления и возвращает одно число — количество гостей